

Allocation Thématique Pilotée par les Nouvelles

Une chaîne de recherche quantitatif fondée sur GDELT et les représentations latentes

Jules D'ALMEIDA

Repository: https://github.com/Aurami11/price_transformer

31 juillet 2026

Résumé

Ce projet propose une chaîne expérimentale de recherche quantitative qui convertit des événements médiatiques issus de GDELT en signaux thématiques, puis en allocations actions. Un même modèle de phrases encode les nouvelles, les thèmes d'investissement et les descriptions d'entreprises ; cette représentation partagée permet de relier l'information macro-médiatique à un univers d'actifs sans construire manuellement une taxonomie sectorielle exhaustive. La chaîne couvre l'ingestion historique, la construction des signaux, la projection sémantique vers les actifs, le backtest, l'analyse de sensibilité et la visualisation interactive. L'objectif est méthodologique : évaluer une hypothèse de transmission entre intensité/sentiment des nouvelles et rendements futurs, et non produire une recommandation d'investissement.

Table des matières

1	Problématique et contribution	2
2	Vue d'ensemble de l'architecture	2
3	Représentation latente des nouvelles	2
3.1	Concepts et sentiments	2
3.2	Choix des prompts	3
4	Pipeline GDELT et temporalité	3
5	Projection des thèmes vers les actions	3
6	Construction et backtest du portefeuille	4
7	Restitution et reproductibilité	4
8	Protocole expérimental recommandé	4
9	Limites et axes d'amélioration	5
10	Conclusion	5

1 Problématique et contribution

Les nouvelles financières et géopolitiques sont abondantes, hétérogènes et difficilement exploitables dans un cadre de portefeuille. Le problème étudié consiste à transformer un flux d'événements textuels en un signal quotidien, interprétable et projetable sur des titres cotés. L'approche proposée sépare explicitement trois objets : les thèmes économiques, le ton directionnel des informations, et l'exposition économique des entreprises à ces thèmes.

La contribution principale est une architecture de *semantic factor investing*. Au lieu d'associer un mot-clé à une action par règles déterministes, le système emploie des embeddings de texte et des similarités cosinus. La matrice d'exposition résultante joue un rôle analogue à une matrice de charges factorielles, tandis que les signaux GDELT forment des facteurs thématiques dynamiques.

2 Vue d'ensemble de l'architecture

La chaîne est organisée en six modules Python indépendants, afin de séparer les responsabilités de données, de modélisation et de restitution.

TABLE 1 – Responsabilités des principaux composants.

Module	Fonction
<code>latent_signal_generator.py</code>	Définition des concepts et sentiments, encodage textuel et production du signal directionnel.
<code>auto_portfolio_allocator.py</code>	Téléchargement et mise en cache des descriptions d'entreprises, puis construction de la matrice d'exposition $\mathbf{W}$.
<code>gdelt_historical_pipeline.py</code>	Traitement historique des fichiers GDELT, extraction des pays et du texte, alignement temporel et agrégation.
<code>backtest_engine.py</code>	Récupération des prix ajustés, calcul des rendements futurs, construction des poids et simulation des stratégies.
<code>reporting_engine.py</code>	Analyse de sensibilité et génération d'un rapport HTML interactif.
<code>app.py</code>	Tableau de bord Streamlit permettant de modifier dynamiquement les paramètres du backtest.

GDELT historique → nettoyage/extraction textuelle → embeddings et signal par concept → agrégation temporelle → projection via $\mathbf{W}$ → classement des actifs → portefeuille et évaluation

FIGURE 1 – Flux de données et de décision.

3 Représentation latente des nouvelles

3.1 Concepts et sentiments

Le moteur `LatentSpaceIndicator` utilise `all-mpnet-base-v2` de Sentence-Transformers. Chaque concept c (par exemple intelligence artificielle ou énergie renouvelable) est décrit par un ensemble de phrases $\mathcal{K}_c$. Son centroïde latent est

$$\mathbf{z}_c = \frac{1}{|\mathcal{K}_c|} \sum_{k \in \mathcal{K}_c} \text{Embed}(k).$$

Deux autres collections de phrases définissent des centroïdes de sentiment positif et négatif. Pour une nouvelle x , le système calcule une pertinence thématique et un différentiel de sentiment :

$$r_c(x) = \max(0, \cos(\mathbf{z}_x, \mathbf{z}_c)), \quad m(x) = s_+(x) - s_-(x),$$

avec s_+ et s_- les similarités positives tronquées à zéro. Le signal directionnel élémentaire devient

$$g_c(x) = r_c(x) m(x).$$

Cette formulation réduit l'impact des textes hors thème et donne un signe au signal : une nouvelle négative et fortement liée à un concept produit une contribution négative.

3.2 Choix des prompts

Les phrases de définition constituent un hyperparamètre central. Elles doivent être spécifiques au mécanisme économique recherché, diversifiées lexicalement, et stables dans le temps. Les prompts de sentiment doivent être suffisamment polarisés afin de distinguer une information favorable d'une information défavorable. Toute étude de robustesse doit donc tester plusieurs dictionnaires de concepts et de formulations.

4 Pipeline GDELT et temporalité

Les fichiers `.slim.parquet` sont lus par lots avec un mécanisme de reprise sur cache Parquet. Le pipeline extrait les pays depuis `V2Locations`, puis construit un pseudo-texte. Il privilégie d'abord un titre extrait de l'URL ; si celui-ci est insuffisant, il synthétise un texte à partir des thèmes, organisations et du ton GDELT. La méthode d'extraction est conservée avec chaque observation pour faciliter l'audit des données.

Toutes les dates sont converties en heure de New York. Les observations postérieures à 16h00 sont affectées au jour ouvré suivant ; les observations de week-end sont également reportées. Ce choix vise à éviter d'attribuer rétrospectivement à la séance t une information qui n'était disponible qu'après sa clôture.

Après agrégation par date de trading, concept, pays et session, le pipeline calcule deux transformations :

$$\text{EMA}_{5,t} = \text{EMA}(g_t; 5), \quad Z_{20,t} = \frac{g_t - \mu_{20,t}}{\sigma_{20,t}},$$

où la seconde est calculée avec une fenêtre glissante de 20 observations et un minimum de cinq observations. L'EMA représente la persistance du flux informationnel, alors que le Z-score met l'accent sur les surprises relatives à l'historique récent.

5 Projection des thèmes vers les actions

Pour chaque titre i , une description métier est récupérée et mise en cache localement. La charge sémantique de l'actif i au concept c est donnée par

$$W_{i,c} = \mathbb{I}\{\cos(\mathbf{e}_i, \mathbf{z}_c) \geq \tau\} \cos(\mathbf{e}_i, \mathbf{z}_c),$$

où $\mathbf{e}_i$ est l'embedding de la description de l'entreprise et $\tau = 0.15$ est le seuil anti-bruit par défaut. La matrice $\mathbf{W} \in \mathbb{R}^{N \times C}$ est conservée brute ; une version normalisée par colonne est aussi disponible pour des analyses alternatives.

Si $\mathbf{f}_t \in \mathbb{R}^C$ désigne le vecteur quotidien de signaux agrégés par concept, le score d'actif est

$$\mathbf{a}_t = \mathbf{f}_t \mathbf{W}^\top.$$

Cette opération est transparente : chaque score action peut être décomposé en contributions conceptuelles. Elle permet aussi à une société d'être exposée à plusieurs thèmes, plutôt que d'être forcée dans une catégorie unique.

6 Construction et backtest du portefeuille

Les prix sont récupérés puis mis en cache ; les rendements utilisés sont décalés d’une période :

$$R_{i,t+1} = \frac{P_{i,t+1}}{P_{i,t}} - 1.$$

Le décalage matérialise le principe suivant : un score disponible à la date t doit être évalué contre le rendement subséquent, non contre un rendement déjà observé.

Deux politiques de sélection équipondérée sont implémentées. **longonly** détient les N scores non nuls les plus élevés, avec un poids $1/N$ par titre. **longshort** achète les N meilleurs et vend les N plus faibles, avec des poids respectifs $+1/N$ et $-1/N$. Les dates et colonnes des signaux et des rendements sont explicitement alignées par intersection avant toute multiplication matricielle.

Le rendement de portefeuille est

$$r_{p,t} = \sum_{i=1}^N w_{i,t} R_{i,t+1}, \quad E_t = \prod_{u \leq t} (1 + r_{p,u}).$$

Les métriques reportées incluent rendement cumulé, rendement annualisé, volatilité annualisée, ratio de Sharpe sans taux sans risque explicite et drawdown maximal. Pour une volatilité quotidienne σ_d , la volatilité annualisée est $\sigma_a = \sqrt{252} \sigma_d$.

7 Restitution et reproductibilité

Le moteur de reporting génère une matrice d’exposition exportable, une projection PCA des actifs, une carte de chaleur de $\mathbf{W}$ et une analyse de sensibilité sur les métriques $\{\mathbf{Z20}, \mathbf{EMA5}\}$, les stratégies $\{\text{long-only}, \text{long-short}\}$ et $N \in \{3, 5, 10\}$. Le résultat est un rapport HTML Plotly interactif. L’application Streamlit fournit en complément des onglets pour les performances, l’animation des allocations, les séries par pays, la PCA des pays, la PCA des actifs et la matrice d’exposition.

Pour rendre les expériences reproductibles, il est recommandé de versionner les fichiers de configuration (univers, dates, pays, prompts, seuil τ , paramètres de fenêtres), mais d’exclure les caches volumineux et potentiellement propriétaires. Les versions de Python et des dépendances doivent être figées dans `requirements.txt`.

Listing 1 – Exemple minimal d’exécution. Adapter les noms et chemins au dépôt.

```
python main.py
streamlit run app.py
```

8 Protocole expérimental recommandé

Une performance historique ne suffit pas à établir une capacité prédictive. Les expériences doivent respecter une séparation temporelle stricte entre calibration et évaluation, sans ajuster les prompts ou l’univers sur la période de test. Une validation *walk-forward* est préférable : définir les concepts et paramètres sur une fenêtre passée, les figer, puis les évaluer sur la fenêtre suivante.

Les coûts de transaction, le slippage, la liquidité, les contraintes de vente à découvert, les dividendes, les événements de marché et les biais de survivance ne sont pas modélisés explicitement dans le moteur actuel. Ces éléments peuvent réduire substantiellement la performance réalisée, particulièrement pour les portefeuilles concentrés et les stratégies à rotation élevée. Une version de production devrait intégrer turnover, coûts proportionnels, délais d’exécution, calendrier de rebalancement, et une source de données d’univers historiquement constitués.

Les contrôles minimaux conseillés sont les suivants :

- Comparer la stratégie à des benchmarks simples : équipondéré, momentum, portefeuille sectoriel et tirages aléatoires.
- Tester la stabilité face aux variations de τ , de la fenêtre du Z-score, du span EMA, des prompts et du nombre N .
- Rapporter le nombre de jours investis, le turnover, l'exposition nette/brute et les contributions par actif et concept.
- Auditer un échantillon de pseudo-textes et de scores afin de vérifier la cohérence sémantique.
- Utiliser des tests de placebo : permutation temporelle des signaux ou appariements thème-entreprise aléatoires.

9 Limites et axes d'amélioration

La qualité du signal dépend de la couverture GDELT, du texte reconstruit et de la stabilité des embeddings. Un slug d'URL ou une synthèse de métadonnées ne remplace pas systématiquement le contenu intégral de l'article. De plus, la similarité sémantique entre une description d'entreprise et un thème est une mesure d'affinité textuelle, pas une estimation causale de sensibilité économique.

Les développements prioritaires sont : (i) remplacer les pseudo-textes par des titres ou articles licenciés lorsque possible ; (ii) ajouter un modèle d'exposition temporel et des pondérations régularisées ; (iii) intégrer coûts et contraintes réalistes ; (iv) appliquer une validation walk-forward avec correction du multiple testing ; et (v) enrichir le signal par la source, la nouveauté, le volume d'événements et l'incertitude du modèle.

10 Conclusion

Le projet fournit une base modulaire pour étudier l'investissement thématique à partir de nouvelles mondiales. Son intérêt ne réside pas dans une promesse de rendement, mais dans une chaîne explicable qui relie texte, représentations latentes, facteurs thématiques, expositions d'entreprises et décisions de portefeuille. La prochaine étape scientifique est de transformer ce prototype en protocole empirique rigoureux, robuste aux biais de données et aux frictions de marché.

Références

- [1] N. Reimers et I. Gurevych. *Sentence-BERT : Sentence Embeddings using Siamese BERT-Networks*. EMNLP-IJCNLP, 2019.
- [2] K. Leetaru et P. Schrodt. *GDELT : Global Data on Events, Location and Tone*. ISA Annual Convention, 2013.
- [3] M. Lopez de Prado. *Advances in Financial Machine Learning*. Wiley, 2018.